ANÁLISE DOS FATORES ASSOCIADOS À RECEITA DE FILMES

Luiz Henrique Floriano Querobin; Sara Ferreira Da Silva; Kauã Ferreira Rocha

RESUMO

Este estudo analisa fatores associados à receita de filmes e avalia sua estimação por aprendizado de máquina. Seguimos o CRISP-DM para entender o problema e os dados, preparar a base, treinar e avaliar os modelos e implantar uma consulta local às previsões. A base TMDB contém 1.260.483 registros. Em resposta ao questionamento sobre o volume de dados, a exploração inicial incorpora 12.872.093 títulos do IMDb, incluindo filmes, séries e episódios. Os arquivos complementares são processados em blocos, com tratamento de ausências, validação de campos e seleção de filmes para cruzamento exploratório por identificador. Essa ampliação não modifica a amostra financeira: 25.969 títulos do TMDB com receita positiva, status de lançamento e antecedência mínima de um ano no corte de 18 de outubro de 2026. A preparação inclui imputação, transformação logarítmica e codificação de categorias. A análise utiliza correlações de Spearman e comparações descritivas. A previsão considera características de produção e calendário, excluindo popularidade e avaliações posteriores ao lançamento. Foram comparados um preditor de referência, Ridge e Random Forest com divisão temporal. Após instabilidade inicial da Ridge, uma revisão exploratória transformou também a duração e selecionou Random Forest na validação. No teste reutilizado, o erro absoluto médio foi 15,54 milhões de unidades monetárias nominais e o R^2 foi 0,26, com redução de 24,87% no erro médio frente à referência. Os resultados indicam associação expressiva entre orçamento e receita, mas capacidade preditiva limitada. A cobertura financeira incompleta, os valores nominais e a revisão após inspeção do teste restringem a generalização. O modelo exige confirmação independente antes de uso operacional.

1 INTRODUÇÃO

A receita de uma produção cinematográfica representa uma dimensão observável de seu desempenho comercial. Entretanto, produções com características semelhantes podem alcançar resultados financeiros distintos. A análise de dados permite investigar padrões nessa variação, desde que se diferenciem relações estatísticas, capacidade de previsão e explicações causais. Neste trabalho, a receita registrada na base é a variável de interesse, enquanto orçamento, duração, gêneros, idioma e data de lançamento constituem possíveis atributos explicativos.

A pergunta de pesquisa é: quais características de um filme estão mais relacionadas ao seu sucesso financeiro e é possível utilizar essas características para estimar sua receita? Para tornar a pergunta operacional, o termo sucesso financeiro é delimitado ao volume de receita informado no dataset. O estudo não estabelece uma classificação universal de sucesso e não estima lucro. Uma produção pode arrecadar mais que outra e, ainda assim, apresentar situação econômica menos favorável quando seus custos são considerados.

No primeiro bimestre, planejamos trabalhar apenas com o arquivo do TMDB disponível no Kaggle. No seminário, o professor considerou a base pequena e questionou seu tamanho. Em resposta, acrescentamos o IMDb para ampliar o volume de dados explorados, incluindo registros de séries e episódios. Mantivemos o tema e o CRISP-DM. O IMDb complementou a exploração. A regressão continuou usando a receita registrada no TMDB.

Ao preparar os dados, vimos que o tamanho da base e a disponibilidade de informações financeiras eram problemas diferentes. A maior parte dos registros do TMDB não tinha receita positiva registrada. Por isso, descrevemos tanto a base original quanto o recorte usado na regressão. Também mantivemos os resultados da primeira rodada, porque os erros ajudaram a identificar onde o modelo falhava.

O artigo apresenta objetivos, fundamentos, preparação dos dados, associações e avaliação dos modelos. A discussão distingue utilidade exploratória de prontidão para aplicação e explicita a incerteza dos resultados.

2 OBJETIVOS

O objetivo geral é identificar os principais fatores associados à receita de filmes e avaliar a viabilidade de estimar essa variável mediante modelos supervisionados de regressão, utilizando dados do TMDB e um procedimento organizado pelo CRISP-DM.

Os objetivos específicos são caracterizar a cobertura e a qualidade das variáveis; selecionar registros com alvo financeiro utilizável; tratar ausências e valores não positivos; investigar associações entre características e receita; construir representações adequadas às variáveis numéricas e categóricas; comparar modelos com uma referência simples; medir desempenho em períodos posteriores; e interpretar os limites do valor produzido.

Para a análise descritiva, o trabalho considera também popularidade e avaliações registradas na coleta. Para a previsão orientada ao período anterior ao lançamento, essas informações ficam excluídas. Essa distinção permite estudar as relações propostas no seminário sem pressupor que variáveis observadas depois do lançamento estariam disponíveis no momento da decisão.

3 FUNDAMENTAÇÃO TEÓRICA

O CRISP-DM organiza projetos de mineração de dados em entendimento do negócio, entendimento dos dados, preparação, modelagem, avaliação e implantação. Suas etapas podem exigir retornos às decisões anteriores quando surgem problemas de qualidade ou de adequação dos resultados. Essa organização sustenta o percurso adotado no estudo, incluindo a revisão motivada por erros de previsão (Chapman et al., 2000).

A tarefa supervisionada é de regressão porque a receita assume valores quantitativos. Um classificador de filmes bem avaliados responderia a outra pergunta e exigiria redefinir o alvo. Neste projeto, notas de público são atributos descritivos complementares, enquanto o resultado financeiro permanece o objeto central de modelagem.

A regressão Ridge acrescenta uma penalização aos coeficientes de um modelo linear. O parâmetro de regularização controla essa penalização. No experimento, o método representa uma hipótese relativamente simples de relação entre os atributos transformados e o logaritmo da receita (Scikit-learn, 2026a).

A Random Forest combina árvores e permite representar relações não lineares. A comparação com Ridge possibilita verificar se essa flexibilidade melhora a previsão no recorte utilizado. Sua escolha como candidata não implica superioridade antecipada: a seleção depende dos resultados obtidos na validação (Breiman, 2001).

Um pipeline reúne transformações e estimador. O ColumnTransformer permite aplicar procedimentos diferentes a colunas numéricas e categóricas. O TransformedTargetRegressor transforma o alvo durante o ajuste e aplica a função inversa na previsão. Essas ferramentas organizam o experimento e mantêm as estatísticas de imputação e padronização vinculadas aos conjuntos de ajuste (Scikit-learn, 2026d).

O erro absoluto médio, ou MAE, resume o tamanho médio das diferenças absolutas entre valores reais e previstos. O RMSE atribui maior influência a erros grandes. O R^2 compara a soma dos erros quadráticos com a variação do alvo no conjunto avaliado. Valores negativos podem ocorrer. As três medidas são complementares e não devem ser interpretadas como porcentagem de acerto (Scikit-learn, 2026b).

A importância por permutação mede a alteração de uma métrica após embaralhar um atributo. O resultado depende do modelo e da amostra, e atributos correlacionados podem compartilhar informação. Portanto, a medida ajuda a inspecionar a previsão, mas não demonstra efeito causal (Scikit-learn, 2026c).

No estudo, correlações de Spearman descrevem associações de ordenação entre pares de variáveis. As comparações de gêneros usam contagens e medianas. Esses procedimentos são descritivos: não controlam simultaneamente todas as diferenças entre produções e não fundamentam afirmações de que aumentar um atributo causaria aumento de receita.

4 METODOLOGIA

4.1 Entendimento do negócio e dos dados

O estudo é quantitativo e exploratório, baseado em dados secundários. O cenário de aplicação é a compreensão do desempenho financeiro de produções e a avaliação de uma estimativa anterior ao lançamento. A decisão pretendida seria comparar expectativas de receita a partir de características de produção, sem substituir análise financeira individual.

Utilizou-se o arquivo TMDB_all_movies.csv disponibilizado por Alan Vourc'h no Kaggle. O arquivo fornecido contém 1.260.483 linhas e 30 colunas e ocupa aproximadamente 797 MB. O número de registros difere da apresentação inicial, que descrevia 1.241.618 títulos. As contagens deste artigo correspondem ao arquivo efetivamente analisado, cuja identidade está registrada por SHA-256 no repositório (Vourc'h, [s. d.]).

Para reduzir o uso de memória, o processamento carrega apenas as colunas necessárias. Não foram utilizados sinopses, elenco e demais textos extensos na previsão. A data de corte analítica foi fixada em 18 de outubro de 2026. Essa data não corresponde a uma data de download comprovada nem ao encerramento financeiro de todos os títulos.

Para ampliar a exploração inicial, usamos os arquivos title.basics.tsv.gz e title.ratings.tsv.gz do IMDb. O primeiro reúne vários tipos de título, incluindo séries e episódios. O cruzamento complementa a descrição dos registros, mas não acrescenta receitas nem altera as entradas da regressão. Auditamos as fontes separadamente para evitar contar títulos repetidos como novas observações (IMDb, [s. d.]).

Tabela 1 - Variáveis e usos definidos. Fonte: elaboração dos autores.

Variável	Papel no estudo
revenue	Alvo quantitativo e análise exploratória
budget e runtime	Características de produção
genres e original_language	Características categóricas
release_date	Ano e mês de lançamento
popularity e avaliações	Exploração posterior ao lançamento

4.2 Ampliação inicial com dados do IMDb

Processamos 12.872.093 registros em title.basics e 1.722.371 em title.ratings. O segundo arquivo contém avaliações de títulos que também podem aparecer no primeiro. Por isso, apresentamos as contagens separadamente em vez de somá-las como se fossem títulos distintos.

A leitura foi realizada diretamente dos arquivos gzip, em blocos de 100 mil linhas. O tipo titleType permite distinguir filmes, séries, minisséries e episódios. O recorte movie foi utilizado para construir uma referência complementar de filmes. Séries e demais formatos permanecem nas estatísticas iniciais, mas ficam fora dessa referência.

Tabela 2 - Composição da massa inicial do IMDb. Fonte: elaboração dos autores.

Tipo de título IMDb	Registros
movie	759.771
tvSeries	307.146
tvMiniSeries	73.667
tvEpisode	9.955.259
short	1.164.059
Demais tipos	612.191

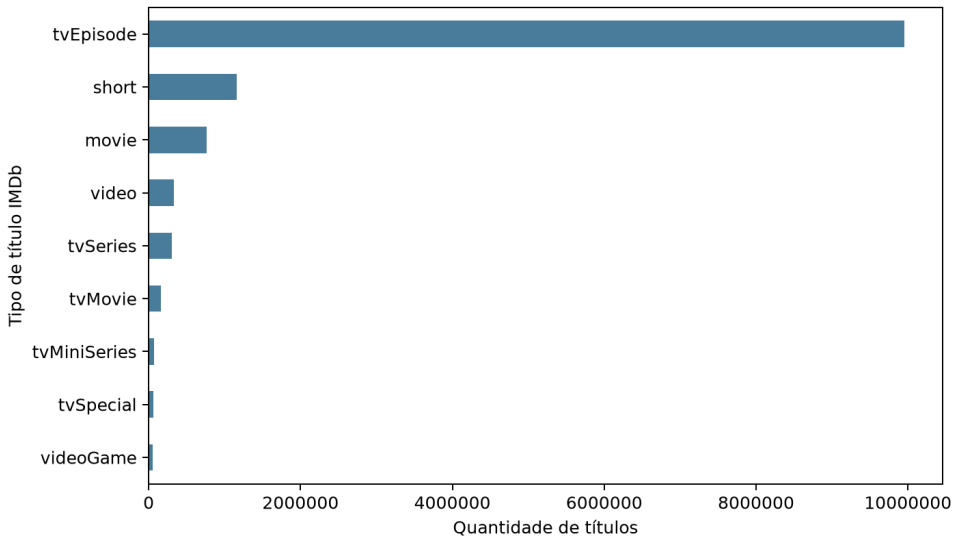


Figura 1 - Tipos de título na exploração inicial do IMDb. Fonte: elaboração dos autores.

4.2 Ampliação inicial com dados do IMDb continuação

Os marcadores de ausência foram convertidos para nulos e os textos tiveram espaços externos removidos. Campos numéricos receberam regras de domínio. Quatro valores inválidos de duração passaram a ausentes e 4.627 anos futuros foram sinalizados. Não houve imputação nessa etapa complementar.

O campo endYear aplica-se a séries e minisséries. Sua ausência em filmes e episódios é estrutural, e não uma falha a preencher pela mediana. Também se verificaram durações não positivas, indicadores adultos fora de zero ou um, notas fora de um a dez, votos não positivos ou não inteiros e ano de término anterior ao início.

Tabela 3 - Ausências no IMDb antes e após o tratamento. Fonte: elaboração dos autores.

Campo	Ausentes antes	Ausentes depois
isAdult	0	0
startYear	1.486.031	1.486.031
endYear	12.708.993	12.708.993
runtimeMinutes	8.013.592	8.013.596
genres	545.089	545.089

O cruzamento por imdb_id e tconst identificou correspondência de metadados para 690.356 linhas do TMDB. O subconjunto de referência com titleType igual a movie contém 385.149 linhas do TMDB. Esses números descrevem cobertura e seleção exploratória, sem aumentar a amostra de receita.

A amostra financeira original contém 21.935 correspondências movie, 2.797 títulos sem correspondência e 1.237 de outros tipos IMDb, incluindo 29 séries ou minisséries e 19 episódios. Essa heterogeneidade já existia no TMDB e constitui uma limitação. A ampliação não acrescentou esses títulos à regressão.

A referência complementar não altera os critérios financeiros. Comparações de hashes confirmaram métricas, previsões e pipeline treinado idênticos. O feedback amplia a etapa inicial sem adicionar séries à regressão.

4.3 Preparação dos dados financeiros

A auditoria inicial não identificou duplicidades no identificador TMDB. Foram mantidos registros com status Released. A receita foi convertida para formato numérico e a data de lançamento foi interpretada como data. Registros sem data válida, com receita ausente ou não positiva e lançados há menos de um ano em relação ao corte foram excluídos. A antecedência mínima é uma regra operacional e não garante receita final consolidada.

Na base bruta, 1.231.476 registros apresentam receita zero, 29.006 possuem receita positiva e um possui receita negativa. Não se interpretou receita zero como fracasso comercial comprovado. Esse valor impede distinguir ausência de informação de arrecadação efetivamente nula. Por isso, tais registros ficam fora da tarefa de regressão.

Orçamentos e durações não positivos foram convertidos em ausentes. No recorte final, as proporções de ausência são 37,09% e 5,50%, respectivamente. A imputação usa a mediana na escala transformada, ajustada no conjunto de treinamento de cada pipeline, com indicadores de ausência. Gênero ausente produz indicadores conhecidos iguais a zero.

Orçamento e receita recebem log(1 + x). A duração também é transformada na rodada revisada. A receita é contínua e assimétrica: não se aplicam balanceamento de classes ou SMOTE. O logaritmo reduz sua amplitude, mas não equaliza a representação de receitas extremas. Ano e mês vêm da data. Gêneros recebem indicadores binários e o idioma, one-hot encoding, com categorias novas ignoradas.

Tabela 4 - Contagens de auditoria financeira. A terceira linha não é uma etapa sequencial.
Fonte: elaboração dos autores.

Etapa	Registros
Base bruta	1.260.483
Status Released	1.236.535
Receita positiva na base bruta	29.006
Amostra após todos os critérios	25.969

4.4 Distribuição e cobertura financeira

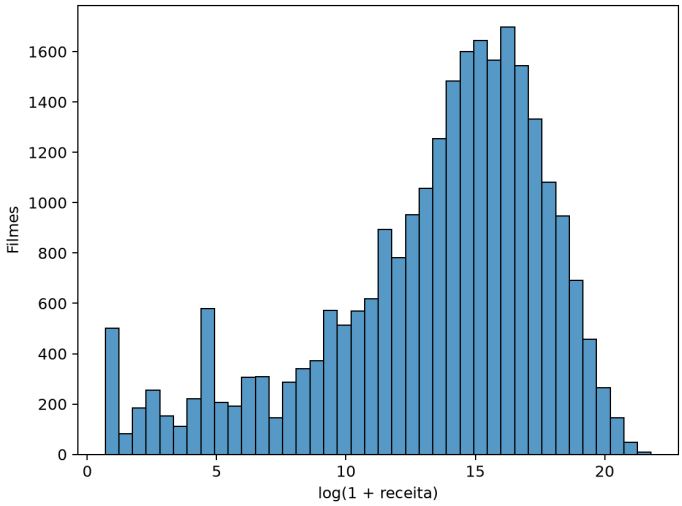


Figura 2 - Distribuição de log(1 + receita) na amostra analítica. Fonte: elaboração dos autores com dados do TMDB.

A distribuição financeira é heterogênea. Na base bruta restrita a receitas positivas, a mediana é 1.275.581 unidades monetárias, o percentil 90 é 64.400.000 e o maior valor registrado é 2.927.449.455. Esses números descrevem o conjunto positivo anterior ao recorte temporal e não substituem as estatísticas dos conjuntos de treinamento e teste.

A transformação logarítmica comprime a amplitude dos valores e facilita a visualização. A transformação do alvo, entretanto, altera a função de ajuste: reduzir erros no espaço logarítmico não equivale a minimizar diretamente o MAE monetário. Por isso, a seleção usa previsões reconvertidas à escala original.

A amostra analítica representa aproximadamente 2,06% das linhas do arquivo. A principal restrição não é o volume computacional, mas a cobertura do resultado financeiro. A seleção pode favorecer títulos cuja arrecadação foi informada e excluir produções de menor visibilidade ou de distribuição distinta. Não se afirma que os filmes excluídos seriam menos bem-sucedidos.

Os valores são analisados como unidades monetárias nominais registradas no arquivo. Não houve validação individual de moeda, conversão, abrangência geográfica ou ajuste de inflação. Comparações entre períodos muito afastados devem, portanto, ser interpretadas com cautela.

4.5 Associações exploratórias

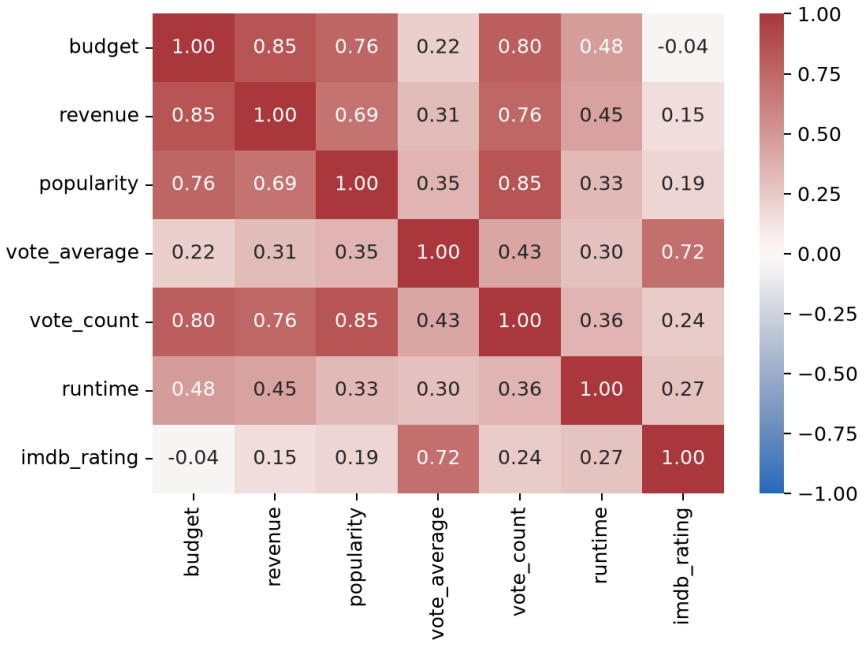


Figura 3 - Correlações de Spearman no recorte analítico, com pares disponíveis. Fonte: elaboração dos autores com dados do TMDB.

O orçamento apresenta correlação de Spearman de aproximadamente 0,85 com a receita. A quantidade de votos apresenta associação de aproximadamente 0,76, e a popularidade, de 0,69. Esses resultados respondem à etapa descritiva proposta no seminário e indicam relações de ordenação no conjunto observado.

As correlações foram calculadas com valores disponíveis por par. Consequentemente, pares diferentes podem utilizar quantidades distintas de títulos. Orçamentos não positivos já foram tratados como ausentes. Os indicadores de avaliações refletem o arquivo recebido e podem apresentar zeros ou cobertura incompleta. Esses indicadores não são utilizados como atributos preditivos.

Popularidade e quantidade de votos podem refletir exposição posterior ao lançamento. Mesmo uma associação alta não justifica utilizá-las para uma previsão anterior à estreia. A direção da relação e os fatores que influenciam simultaneamente visibilidade e receita não foram identificados causalmente neste estudo.

4.6 Gêneros e separação temporal

Tabela 5 - Exemplos de gêneros na amostra analítica. Fonte: elaboração dos autores.

Gênero	Títulos	Mediana da receita
Adventure	3.087	11.348.324
Action	4.568	8.111.866
Comedy	8.738	3.400.000
Drama	12.043	1.600.000
Documentary	1.607	33.145

As medianas variam entre gêneros, mas um filme pode pertencer a mais de um grupo. As contagens, portanto, não formam uma partição da amostra e não devem ser somadas como se fossem categorias exclusivas. As diferenças também podem refletir orçamento, país, época e cobertura financeira. O arquivo revenue_by_genre.csv preserva os demais grupos.

Para a avaliação preditiva, os anos foram ordenados e os cortes escolhidos pela contagem acumulada, aproximadamente em 70% e 85% da amostra. Todos os filmes de um ano permanecem no mesmo conjunto. Os percentuais finais diferem ligeiramente das proporções-alvo por causa dessa regra.

A divisão temporal torna explícita a aplicação a períodos posteriores. Ainda assim, os atributos foram extraídos de uma base atualizada, e não de versões históricas anteriores a cada estreia. O estudo simula a disponibilidade conceitual das características, sem comprovar que seus valores atuais eram idênticos aos conhecidos antes do lançamento.

Tabela 6 - Partições temporais. Fonte: elaboração dos autores.

Conjunto	Período	Títulos	Mediana da receita
Treino	1905–2018	18.862	3.178.558
Validação	2019–2022	3.271	322.000
Teste	2023–2025, até o corte	3.836	66.282

4.6.1 Cobertura e diferenças entre os períodos

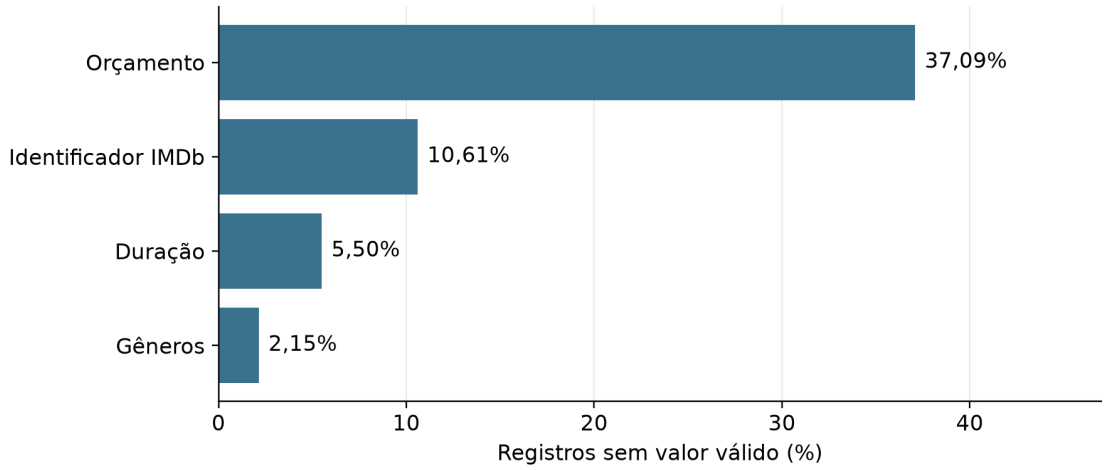


Figura 4 - Atributos ausentes no recorte financeiro de 25.969 títulos. Fonte: elaboração dos autores com dados do TMDB.

O orçamento ficou ausente em 37,09% dos títulos, mais do que os demais campos exibidos. Na regressão, tratamos essas ausências com imputação pela mediana aprendida no treino. O identificador IMDb aparece aqui como informação de cobertura, não como entrada do modelo.

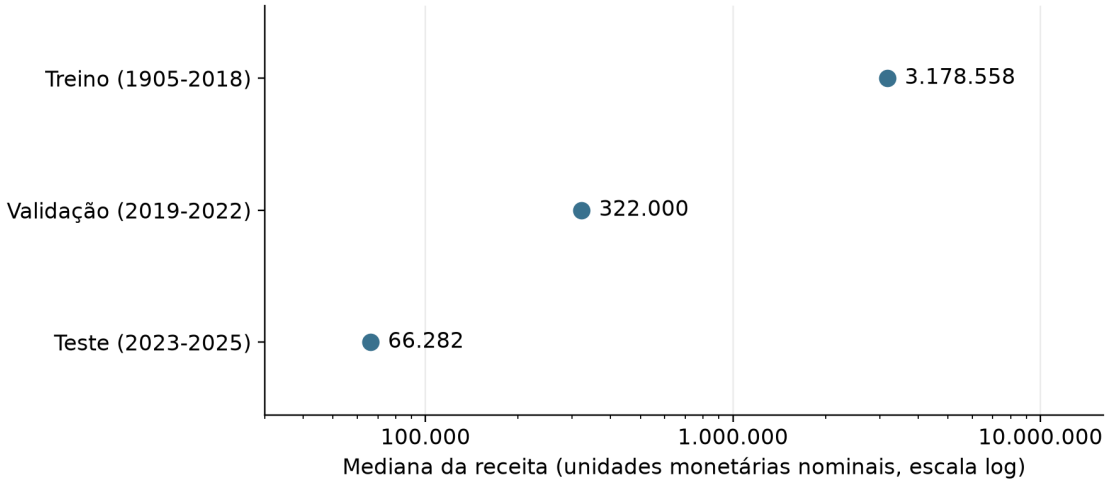


Figura 5 - Mediana da receita registrada em cada partição temporal. Fonte: elaboração dos autores com dados do TMDB.

A mediana observada cai de 3,18 milhões no treino para 66,3 mil no teste. Os períodos reúnem títulos com receitas registradas em escalas bem diferentes. Isso não demonstra que a arrecadação do mercado caiu: a composição da amostra e a cobertura da base também podem variar.

4.7 Modelagem e revisão exploratória

O modelo de referência é DummyRegressor com estratégia de mediana. A Ridge utiliza alpha igual a 10 e solver lsqr. A Random Forest utiliza 300 árvores, mínimo de cinco amostras por folha e semente 42. Não houve busca extensiva de hiperparâmetros. A comparação cobre hipóteses de complexidade distinta, sem pretender esgotar os algoritmos possíveis.

Os atributos numéricos são imputados pela mediana e padronizados dentro do pipeline. A mesma estrutura de preparação é utilizada pelos candidatos, embora árvores não dependam de padronização para funcionar. Os modelos ajustam log(1 + receita), com reconversão por exp(x) - 1 nas previsões. Não foi aplicada correção de viés para estimar a média condicional após essa inversão.

Na primeira rodada, orçamento foi transformado, mas a duração permaneceu na escala original. Ridge apresentou o menor MAE de validação, aproximadamente 20,13 milhões, contra 20,72 milhões da Random Forest. Ao ajustar novamente a configuração escolhida no treino e validação, o teste apresentou MAE de 28,71 milhões, RMSE de 603,08 milhões e R^2 de -37,12.

A inspeção dos erros revelou previsões de aproximadamente 31,71 e 19,20 bilhões para títulos com duração de 546 e 463 minutos. Os valores observados de receita eram aproximadamente 32,12 e 24,99 milhões. Essas durações não foram automaticamente declaradas incorretas: os títulos incluem formatos que desafiam uma interpretação homogênea de filme. O problema observado é a extrapolação do modelo.

Esses erros nos levaram a testar log(1 + duração) para reduzir a distância entre durações comuns e extremas na escala usada pelo modelo. Repetimos a comparação e mantivemos os números da primeira rodada para mostrar o que motivou a mudança. Como examinamos o teste antes desse ajuste e voltamos a usar o mesmo período, a segunda rodada continua exploratória.

4.8 Avaliação dos modelos

Tabela 7 - Validação da rodada revisada. Fonte: elaboração dos autores.

Modelo	MAE milhões	RMSE milhões	R^2
forest	20,74	87,65	0,506
ridge	20,96	103,66	0,308
dummy	26,42	126,67	-0,033

A seleção na rodada revisada considera o menor MAE de validação. Random Forest apresenta vantagem pequena sobre Ridge nessa métrica e menor RMSE. A configuração selecionada é ajustada novamente com treino e validação combinados. O modelo de referência também é ajustado nesse conjunto combinado para comparação no período de teste.

Tabela 8 - Teste reutilizado na revisão exploratória. Fonte: elaboração dos autores.

Modelo	MAE milhões	RMSE milhões	R^2
forest	15,54	84,04	0,260
dummy	20,68	99,22	-0,032

A redução do MAE em relação ao DummyRegressor é de 24,87%. O R^2 de 0,260 significa que a soma dos erros quadráticos equivale a aproximadamente 74% da dispersão quadrática em torno da média do teste. Isso não representa 26% de acurácia. O RMSE de 84,04 milhões evidencia erros grandes. Essas métricas não estabelecem, isoladamente, adequação para decisões de investimento.

4.9 Ferramentas reprodução e implantação

A implementação utiliza Python. Pandas realiza leitura, filtragem, integração, conversão de campos e agregações. NumPy realiza operações numéricas, tratamento por valores nulos e transformações logarítmicas. Matplotlib configura e exporta os gráficos, e Seaborn produz histogramas e mapas de correlação. Scikit-Learn implementa imputação, codificação, padronização, modelos, métricas e importância por permutação. As versões efetivamente utilizadas estão registradas na auditoria.

A reprodução requer o CSV do TMDB e os dois arquivos compactados do IMDb. Os scripts baixar_imdb.py e explorar_imdb.py executam a etapa complementar. O script treinar_inicial.py preserva a primeira rodada e treinar.py executa a revisão. As estatísticas de cobertura do IMDb não são entradas da regressão. Hashes e datas identificam os arquivos, pois a atualização das fontes pode alterar resultados.

Tabela 9 - Ambiente registrado nos experimentos. Fonte: elaboração dos autores.

Ferramenta	Versão	Uso executado
Python	3.12.14	Execução dos scripts
NumPy	2.5.4	Transformações numéricas
Pandas	3.0.6	Preparação e integração
Matplotlib	3.11.2	Gráficos e exportação
Seaborn	0.13.2	Histogramas e correlações
Scikit-Learn	1.9.1	Treinamento e avaliação

Salvamos o modelo treinado em model.joblib e usamos prever.py para consultar estimativas localmente. A consulta permite demonstrar como informar os atributos e obter uma previsão. O README registra os comandos para reproduzir os experimentos e executar essa consulta.

5 RESULTADOS E DISCUSSÃO

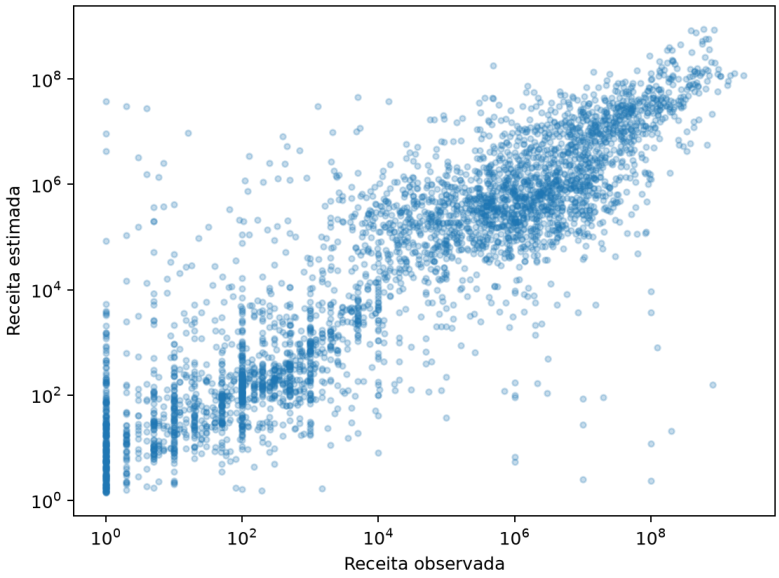


Figura 6 - Receita observada e prevista no teste da rodada revisada. Fonte: elaboração dos autores com dados do TMDB.

A dispersão entre valores observados e previstos confirma que as estimativas não acompanham todos os extremos. O gráfico utiliza escalas transformadas para acomodar a amplitude das receitas. A aparência visual não substitui as métricas calculadas na escala original. Os identificadores, anos e previsões individuais estão registrados em test_predictions.csv.

A importância por permutação foi calculada na validação, com cinco repetições e aumento do MAE como medida. O embaralhamento de log_budget elevou o erro médio em aproximadamente 14,54 milhões. Para mês e log_runtime, os aumentos foram de aproximadamente 0,32 e 0,27 milhão. No modelo e na partição analisados, o orçamento concentra a maior contribuição preditiva medida.

Esses resultados são compatíveis com a associação exploratória entre orçamento e receita, mas não quantificam retorno causal de investimento adicional. Orçamentos ausentes, características correlacionadas e diferentes contextos de produção podem alterar a importância. A medida corresponde à Random Forest ajustada no treino e inspecionada na validação, não ao modelo reajustado no conjunto combinado.

5.1 Erro por faixa de receita

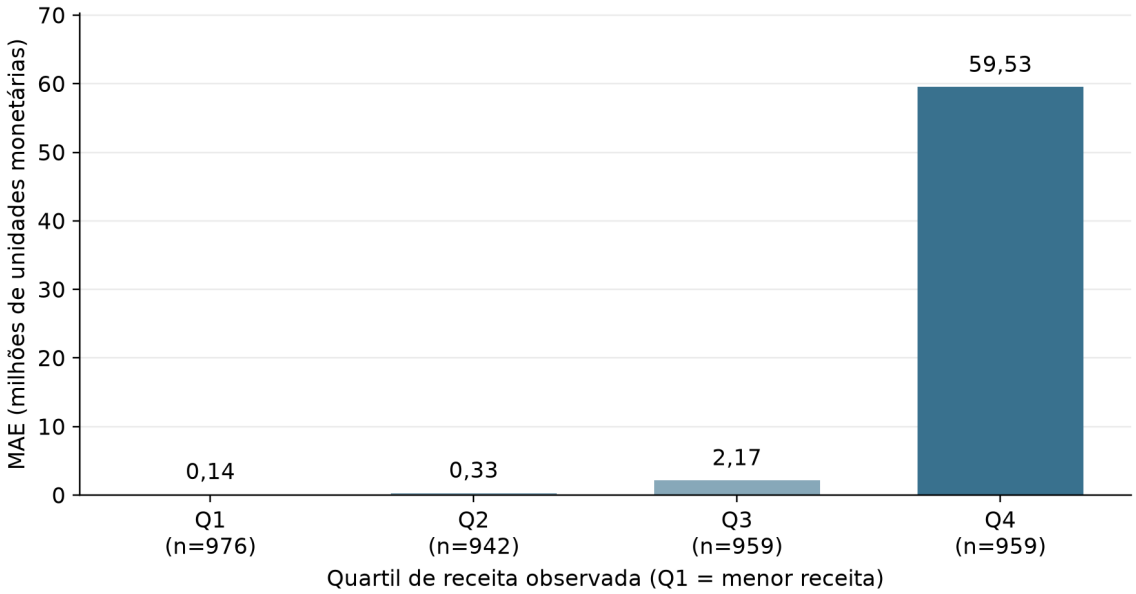


Figura 7 - Erro absoluto médio da Random Forest por quartil de receita no teste reutilizado.
Fonte: elaboração dos autores com dados do TMDB.

Para localizar os erros maiores, separamos os títulos do teste em quatro grupos pela receita observada. Os grupos têm tamanhos semelhantes, mas não idênticos, porque receitas empatadas foram mantidas na mesma faixa. Esse agrupamento foi feito depois da previsão e não foi usado no treinamento.

No quartil superior, que começa em 3,10 milhões de receita observada, o erro absoluto médio foi de 59,53 milhões. No quartil imediatamente abaixo, foi de 2,17 milhões. O quartil superior reúne aproximadamente um quarto dos títulos e responde por cerca de 96% da soma dos erros absolutos do teste.

Essa concentração mostra por que vale olhar além da média geral. O gráfico mede erros em unidades monetárias, não em termos percentuais: ele identifica onde os desvios absolutos foram maiores, mas não mede a precisão relativa de cada faixa. Como usamos as previsões do teste já consultado, a comparação continua exploratória.

5.2 Limitações e conclusões

A investigação encontrou associações entre características de produção e receita, com destaque para orçamento. A configuração revisada apresentou melhora em relação a uma referência simples, porém manteve erro monetário elevado e desempenho sujeito a mudanças temporais. Assim, a resposta à pergunta de pesquisa é parcial: existe informação útil nos atributos observados, mas a confiabilidade alcançada é insuficiente para afirmar capacidade operacional de previsão financeira individual.

O maior aprendizado veio dos erros da primeira Ridge: o menor MAE na validação não impediu que o modelo previsse receitas na casa dos bilhões para títulos de duração extrema. A rodada seguinte teve resultados melhores no mesmo período, mas a transformação da duração foi decidida depois de observar aqueles erros. Para saber se a melhora se mantém, precisamos avaliar a configuração em uma nova amostra.

As principais limitações são a exclusão de grande parte da base por ausência de receita positiva, os valores financeiros sem auditoria individual e sem correção inflacionária, a heterogeneidade de formatos, o uso de uma fotografia atualizada das características e a reutilização do teste após a revisão. A diferença entre medianas de receita nos períodos também sugere mudança de composição ou de cobertura, sem permitir identificar sua causa.

Como continuidade, recomenda-se estabelecer previamente critérios de duração e formato, revisar os registros financeiros, avaliar recortes históricos comparáveis e usar múltiplas janelas temporais de validação. Uma nova amostra independente deve ser reservada para confirmar a configuração revisada. Estudos futuros podem comparar outras funções de perda, modelos de quantis e intervalos de previsão, desde que o protocolo seja definido antes de acessar os novos resultados.

Na prática, usaríamos o modelo para comparar estimativas preliminares entre títulos semelhantes e investigar previsões muito distantes dos valores observados. O tamanho dos erros e a falta de um teste independente ainda limitam seu uso em decisões financeiras.

REFERÊNCIAS

BREIMAN, Leo. Random forests. **Machine Learning**, v. 45, p. 5-32, 2001. DOI: 10.1023/A:1010933404324. Disponível em: https://stat-www.berkeley.edu/~breiman/randomforest2001.pdf. Acesso em: 18 out. 2026.

CHAPMAN, Pete et al. **CRISP-DM 1.0**: step-by-step data mining guide. [S. l.]: SPSS, 2000. Disponível em: https://public.dhe.ibm.com/software/analytics/spss/documentation/modeler/14.2/es/CRISP-DM.pdf. Acesso em: 18 out. 2026.

IMDB. **IMDb non-commercial datasets**. [S. l.], [s. d.]. Disponível em: https://data.imdb.com/non-commercial-datasets/. Acesso em: 18 out. 2026.

SCIKIT-LEARN. **Linear models**. Documentação da versão 1.9.1, 2026a. Disponível em: https://scikit-learn.org/stable/modules/linear_model.html. Acesso em: 18 out. 2026.

SCIKIT-LEARN. **Metrics and scoring**: quantifying the quality of predictions. Documentação da versão 1.9.1, 2026b. Disponível em: https://scikit-learn.org/stable/modules/model_evaluation.html. Acesso em: 18 out. 2026.

SCIKIT-LEARN. **Permutation feature importance**. Documentação da versão 1.9.1, 2026c. Disponível em: https://scikit-learn.org/stable/modules/permutation_importance.html. Acesso em: 18 out. 2026.

SCIKIT-LEARN. **Pipelines and composite estimators**. Documentação da versão 1.9.1, 2026d. Disponível em: https://scikit-learn.org/stable/modules/compose.html. Acesso em: 18 out. 2026.

VOURC'H, Alan. **The ultimate 1Million movies dataset (TMDB + IMDb)**. Kaggle, [s. d.]. Disponível em: https://www.kaggle.com/datasets/alanvourch/tmdb-movies-daily-updates. Acesso em: 18 out. 2026.